Nextflow

Initiation sur genobioinfo

Rapport de mini projet

BALDE Mamadou Hawa

Master de Bioinformatique et Biologie des systèmes
Université de Toulouse – 2025/2026

1- Introduction :

L'analyse de données de séquençage haut débit nécessite aujourd'hui des outils capables d'automatiser un grand nombre d'étapes, depuis le contrôle qualité des lectures jusqu'à l'obtention de résultats exploitables. Nextflow est un gestionnaire de workflows largement utilisé en bioinformatique pour organiser ce type d'analyses, que ce soit sur un ordinateur personnel, un cluster de calcul ou dans le cloud [Di Tommaso et al., 2017].

La communauté nf-core met à disposition une collection de pipelines bioinformatiques validés, réutilisables et conçus pour être reproductibles [Ewels et al., 2020]. Parmi eux, le pipeline nf-core/rnavar est dédié à l'analyse de données RNA-Seq pour la détection de variants (SNPs et indels). Il intègre plusieurs outils de référence comme STAR pour l'alignement des lectures, GATK pour l'appel de variants, Samtools pour les statistiques, et MultiQC pour le résumé global des résultats.

Dans ce travail, nous avons appliqué **nf-core/rnavar** à deux échantillons de **Gadus morhua** (cabillaud), disponibles sur la base publique NCBI (**SRR2045415 et SRR2045416**). Le génome de référence et son annotation transcriptomique ont été utilisés pour guider les étapes d'alignement et de détection des variants. L'objectif est d'illustrer l'utilisation d'un pipeline nf-core sur le cluster de calcul Genotoul, en décrivant les principales étapes techniques et en présentant les résultats obtenus.

2- Materiels et Méthodes :

2.1 Préparation des données :

Dans ce projet, nous avons choisi d'analyser deux échantillons de Gadus morhua (cabillaud) disponibles sur la base de données publique NCBI Sequence Read Archive (SRA) : SRR2045415 et SRR2045416

Ces jeux de données correspondent à des lectures de séquençage RNA-Seq au format FASTQ. En complément, nous avons récupéré :

- Le génome de référence de Gadus morhua au format FASTA,
- L'annotation correspondante au format GTF.

a- Téléchargement des fichiers FASTQ :

Comme l'espace disque de notre poste initial était limité, nous avons choisi de nous connecter au compte **guest** d'un autre ordinateur de la faculté disposant d'une capacité de stockage plus importante.

Nous y avons installé le logiciel **SRA Toolkit**, qui permet de télécharger et de convertir les données de séquençage issues de la base **NCBI Sequence Read Archive (SRA)**.

```
(base) ### Thu Oct 02 14:42  guest pc-bioinfo-3d.univ-tlse3.fr ~
$ conda activate sra-tools
(sra-tools) ### Thu Oct 02 14:43  guest pc-bioinfo-3d.univ-tlse3.fr ~
$ pwd
/home/guest
(sra-tools) ### Thu Oct 02 14:50  guest pc-bioinfo-3d.univ-tlse3.fr ~
$ faterq-dump SRR2045416 --split-files -O .
bash: faterq-dump: command not found
(sra-tools) ### Thu Oct 02 14:55  guest pc-bioinfo-3d.univ-tlse3.fr ~
$ faterq-dump -- version
bash: faterq-dump: command not found
(sra-tools) ### Thu Oct 02 14:55  guest pc-bioinfo-3d.univ-tlse3.fr ~
$ fasterq-dump SRR2045416 --split-files -O .
spots read      : 36,457,070
reads read      : 72,914,140
reads written   : 72,914,140
(sra-tools) ### Thu Oct 02 15:35  guest pc-bioinfo-3d.univ-tlse3.fr ~
$ ls
bin  Desktop  Documents  Downloads  miniforge3  miniforge3.0  Music  Pictures  Public  SRR2045416_1.fastq  SRR2045416_2.fastq  Templates  tmp  Videos
(sra-tools) ### Thu Oct 02 15:43  guest pc-bioinfo-3d.univ-tlse3.fr ~
$ fasterq-dump SRR2045415 --split-files -O .
spots read      : 22,436,517
reads read      : 44,873,034
reads written   : 44,873,034
(sra-tools) ### Thu Oct 02 16:10  guest pc-bioinfo-3d.univ-tlse3.fr ~
$ ls
bin  Desktop  Documents  Downloads  miniforge3  miniforge3.0  Music  Pictures  Public  SRR2045415_1.fastq  SRR2045415_2.fastq  SRR2045416_1.fastq  SRR2045416_2.fastq  Templates  tmp  Videos
```

Fonction de la commande :

- **fasterq-dump** est un outil de SRA Toolkit qui permet de convertir un identifiant SRA (SRR...) en fichiers FASTQ, directement exploitables pour les analyses de bioinformatique.
- **L'option --split-files** sépare les lectures paired-end en deux fichiers distincts :
  - ***_1.fastq** pour les lectures de gauche (Read 1)
  - ***_2.fastq** pour les lectures de droite (Read 2)
- **L'option -O .** précise le dossier de sortie (. = répertoire courant).

Résultat obtenu :

À la fin de l'exécution, la commande affiche le nombre de lectures extraites (spots, reads) et génère deux fichiers FASTQ pour chaque échantillon :

`SRR2045415_1.fastq`

`SRR2045415_2.fastq`

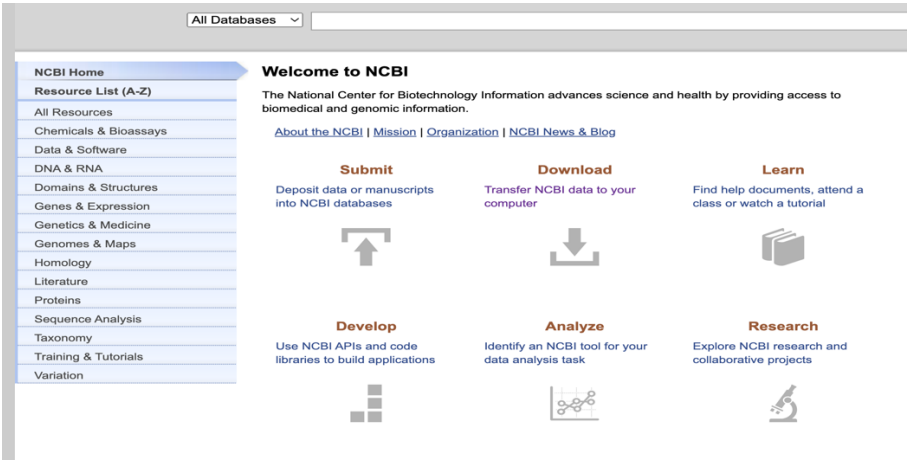
`SRR2045416_1.fastq`

`SRR2045416_2.fastq`

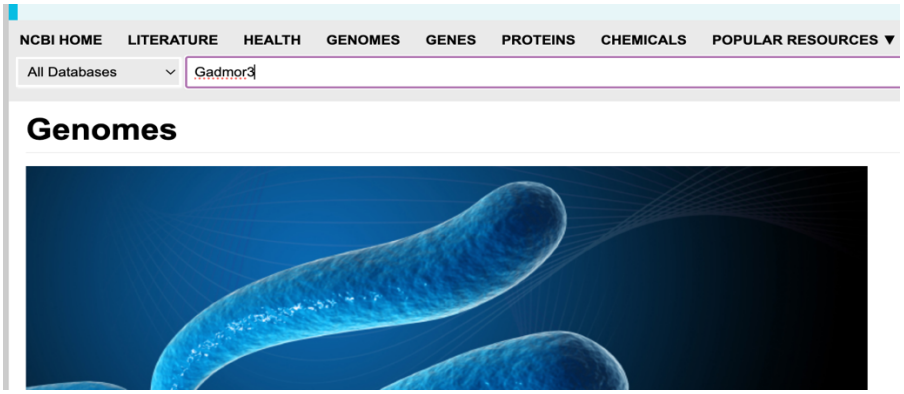
b- Téléchargement du génome de référence et des annotations :

Nous avons récupéré le **génome de référence Gadus morhua et** le fichier d'**annotation** correspondant depuis la base de données NCBI.

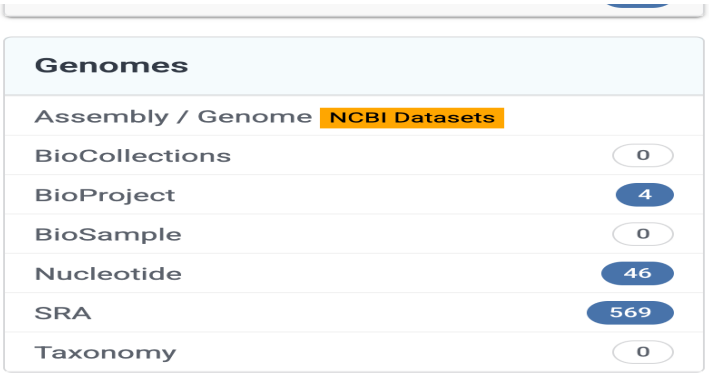
- Clique sur Download



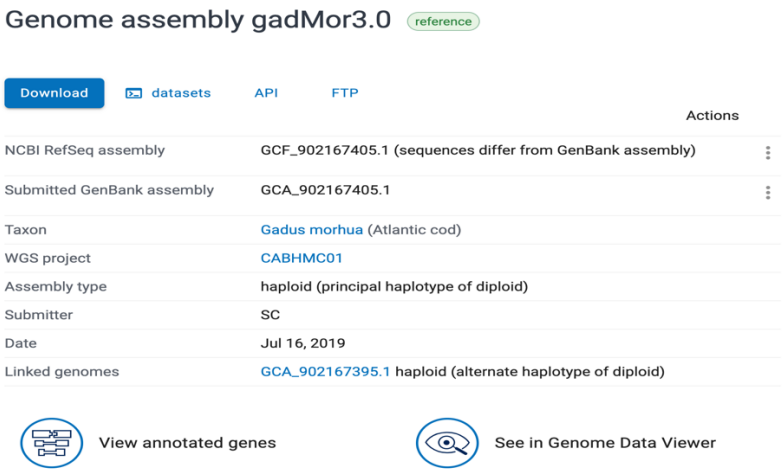
- Dans « genomes », rechercher **Gadmor3**

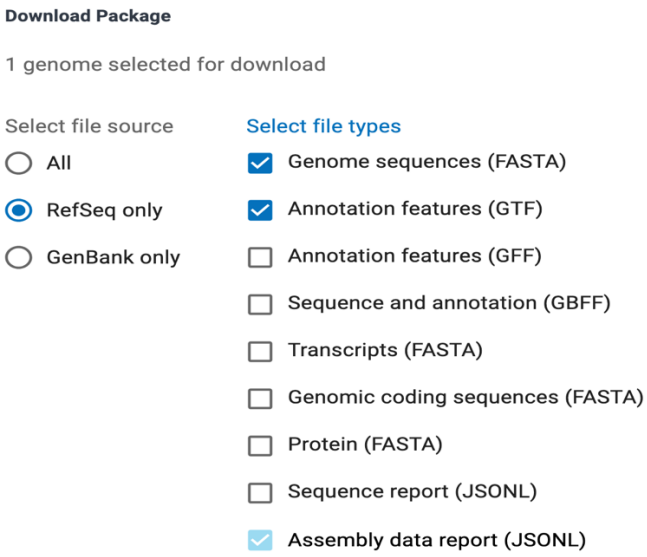


- Clique sur Assembly / Genome | NCBI Datasets



- Puis on clique sur Download afin d'avoir les fichiers.





Les fichiers du génome et de l'annotation téléchargés étaient compressés**.** Nous avons procédé à leur décompression directement sur le PC de la faculté.

Résultat obtenu :

À la fin de cette étape, Nous avions donc :

- **Un génome de référence** : GCF_902167405.1_gadMor3.0_genomic.fna
- **Une annotation associée** : genomic.gtf

Ainsi, Nous avons créé un répertoire de travail spécifique : **data_GM**

Où nous avons organisé les données en trois sous-dossiers :

- GM_fastq/ pour les fichiers FASTQ des échantillons (SRR2045415 et SRR2045416),
- GM_genome/ pour le fichier de génome de référence,

- GM_Annotation/ pour le fichier d'annotation GTF.

c- Import des données sur le cluster genotoul :

Pour cela, Nous avons utilisé une connexion **SCP** qui permet de copier des fichiers depuis un poste local vers un espace de travail distant :

```
$ pwd
/home/guest/Downloads
(sra-tools) ### Thu Oct 02 16:33  guest pc-bioinfo-3d.univ-tlse3.fr ~/Downloads
$ scp -r /home/guest/Downloads/data_GM fmt112@genobioinfo.toulouse.inrae.fr:/work/user/fmt112
The authenticity of host 'genobioinfo.toulouse.inrae.fr (147.100.181.101)' can't be established.
ED25519 key fingerprint is SHA256:XvEBx56QF+5LGAELabubxsV9H1yV/ni1mJHzo2G0O88.
This key is not known by any other names.
Are you sure you want to continue connecting (yes/no/[fingerprint])? y
Please type 'yes', 'no' or the fingerprint: yes
Warning: Permanently added 'genobioinfo.toulouse.inrae.fr' (ED25519) to the list of known hosts.
fmt112@genobioinfo.toulouse.inrae.fr's password:
genomic.gtf                                   100%  541MB 106.6MB/s   00:05
SRR2045415_1.fastq                            100% 7469MB 102.9MB/s   01:12
SRR2045416_1.fastq                            100%   12GB 107.2MB/s   01:53
SRR2045415_2.fastq                            100% 7469MB 102.1MB/s   01:13
SRR2045416_2.fastq                            100%   12GB 105.5MB/s   01:55
GCF_902167405.1_gadMor3.0_genomic.fna         100%  647MB 105.0MB/s   00:06
(sra-tools) ### Thu Oct 02 16:44  guest pc-bioinfo-3d.univ-tlse3.fr ~/Downloads
$
```

2.2 Préparation et exécution du pipeline Nextflow

a) Connexion au cluster et vérification des données :

```
(base) MacBook-Air-de-Hawa:~ hawabalde$ ssh fmt112@genobioinfo.toulouse.inrae.fr
fmt112@genobioinfo.toulouse.inrae.fr's password:
Register this system with Red Hat Insights: insights-client --register
Create an account or view all your systems at https://red.ht/insights-dashboard
Last login: Thu Oct  2 16:52:54 2025 from 195.220.58.236

fmt112@genobioinfo2 ~ $ cd work
fmt112@genobioinfo2 ~/work $ ls
2.fastq         2_fastqc.zip  Hawa          HB.fasta        myscript.sh  slurm-24835964.out
2_fastqc.html   data_GM       HB_20.fasta   HB_nbLines.txt  quality.sh   slurm-24848615.err
fmt112@genobioinfo2 ~/work $ cd data_GM/
fmt112@genobioinfo2 ~/work/data_GM $ ls
GM_Annotation  GM_fastq  GM_genome
```

Nous nous sommes connectés au cluster **Genotoul** à l'aide de notre compte personnel (ssh fmt112@genobioinfo.toulouse.inrae.fr).
Une fois connectés, nous avons navigué dans notre répertoire de travail (~/work/data_GM/) afin de **vérifier que les fichiers importés étaient bien présents**.
La commande ls a permis de confirmer la présence des trois dossiers :

- GM_fastq/ contenant les fichiers **FASTQ** des échantillons SRR2045415 et SRR2045416,
- GM_genome/ contenant le génome de référence en format FASTA,
- GM_Annotation/ contenant le fichier d'annotation GTF.

b) Création du fichier d'échantillons (samplesheet CSV) :

```
fmt112@genobioinfo2 ~/work/data_GM $ cat > samplesheet.csv <<'CSV'
> sample,fastq_1,fastq_2,strandedness
> SRR2045415,/home/fmt112/work/data_GM/GM_fastq/SRR2045415_1.fastq,/home/fmt112/work/data_GM/GM_fastq/SRR2045415_2.fastq,auto
> SRR2045416,/home/fmt112/work/data_GM/GM_fastq/SRR2045416_1.fastq,/home/fmt112/work/data_GM/GM_fastq/SRR2045416_2.fastq,auto
> CSV
fmt112@genobioinfo2 ~/work/data_GM $ column -s, -t samplesheet.csv | sed -n '1,5p'
sample      fastq_1                                                fastq_2                                                strandedness
SRR2045415  /home/fmt112/work/data_GM/GM_fastq/SRR2045415_1.fastq  /home/fmt112/work/data_GM/GM_fastq/SRR2045415_2.fastq  auto
SRR2045416  /home/fmt112/work/data_GM/GM_fastq/SRR2045416_1.fastq  /home/fmt112/work/data_GM/GM_fastq/SRR2045416_2.fastq  auto
fmt112@genobioinfo2 ~/work/data_GM $ ls
GM_Annotation  GM_fastq  GM_genome  samplesheet.csv
```

Le pipeline **nf-core/rnavar** nécessite un fichier CSV décrivant les échantillons.
Nous avons donc créé un fichier `samplesheet.csv` qui contient les chemins complets vers les fichiers FASTQ

c) Préparation du script batch :

- **Première version** : Dans un premier temps, nous avons rédigé un script batch `run_rnavar.sbatch` (voir capture ci-dessous)

```
[fmt112@genobioinfo2 ~/work/data_GM $ more run_rnavar.sbatch
#!/bin/bash
#SBATCH -J rnavar
#SBATCH --cpus-per-task=8
#SBATCH --mem=32G
#SBATCH --time=24:00:00
#SBATCH -o slurm-%j.out
#SBATCH -p unlimitq

set -euo pipefail

module purge
module load devel/java/17.0.6
module load bioinfo/Nextflow/24.10.2
module load containers/singularity/3.9.9

export NXF_SINGULARITY_CACHEDIR="$HOME/singularity_cache"
mkdir -p "$NXF_SINGULARITY_CACHEDIR"

cd /home/fmt112/work/data_GM

nextflow run nf-core/rnavar \
  -r 1.0.0 \
  -profile singularity \
  -c sm_config.cfg \
  --input   /home/fmt112/work/data_GM/samplesheet.csv \
  --fasta   /home/fmt112/work/data_GM/GM_genome/GCF_902167405.1_gadMor3.0_genomic.fna \
  --gtf     /home/fmt112/work/data_GM/GM_Annotation/genomic.gtf \
  --outdir  /home/fmt112/work/data_GM/results_rnavar \
  -work-dir "$PWD/work_rnavar" \
  -resume
```

Puis, nous avons essayé de run et des erreurs ont apparus (voir capture ci-dessus).

```
fmt112@genobioinfo2 ~/work/data_GM $ nano run_rnavar.sbatch
fmt112@genobioinfo2 ~/work/data_GM $ sbatch run_rnavar.sbatch
Submitted batch job 25038540
fmt112@genobioinfo2 ~/work/data_GM $ tail -f slurm-25038540.out
Nextflow 25.04.7 is available - Please consider updating your version to it

 N E X T F L O W   ~  version 24.10.2

Pulling nf-core/rnavar ...
 downloaded from https://github.com/nf-core/rnavar.git
Launching `https://github.com/nf-core/rnavar` [peaceful_leakey] DSL2 - revision: 85b98d51c6 [1.0.0]
```

```
!! Only displaying parameters that differ from the pipeline defaults !!
------------------------------------------------------
If you use nf-core/rnavar for your analysis please cite:

* The nf-core framework
  https://doi.org/10.1038/s41587-020-0439-x

* Software dependencies
  https://github.com/nf-core/rnavar/blob/master/CITATIONS.md
------------------------------------------------------
ERROR ~ Known variants VCF file or its index is missing!. At least --dbsnp (and its index) or --known_indels (and its index) is required.

 -- Check '.nextflow.log' file for details
^C
```

- **Deuxième version du script corrigée :**

Après les erreurs rencontrées avec la première version, nous avons réécrit le script batch pour l'adapter au cluster Genotoul. Les principales modifications apportées sont :

- **Profil** : remplacement de -profile singularity par -profile genotoul (profil déjà configuré pour le cluster).
- **Version** : mise à jour de Nextflow vers la version **25.04.0** et du pipeline rnavar en **1.2.1**.
- **Modules** : suppression du module singularity, ajout du module spécifique nfcore-Nextflow-v25.04.0.
- **Chemins** : utilisation de $PWD pour simplifier les chemins vers les fichiers et éviter les erreurs.
- **Options** : ajout de --skip_baserecalibration pour contourner l'absence de bases de variants connues.

```
[#!/bin/bash
[#SBATCH -J rnavar
[#SBATCH --cpus-per-task=8
[#SBATCH --mem=32G
[#SBATCH --time=24:00:00
[#SBATCH -o slurm-%j.out
 #SBATCH -p unlimitq

set -euo pipefail

module purge
module load devel/java/17.0.6
module load bioinfo/Nextflow/25.04.0
module load bioinfo/NextflowWorkflows/nfcore-Nextflow-v25.04.0

cd ~/work/data_GM
PWD="$(pwd)"

nextflow run nf-core/rnavar \
  -r 1.2.1 \
  -profile genotoul \
  -c sm_config.cfg \
  --input    "$PWD/samplesheet.csv" \
  --fasta    "$PWD/GM_genome/GCF_902167405.1_gadMor3.0_genomic.fna" \
  --gtf      "$PWD/GM_Annotation/genomic.gtf" \
  --outdir   "$PWD/results_rnavar" \
  --skip_baserecalibration \
  -work-dir "$PWD/work_rnavar" \
  -resume
```

Error apres run de la deuxieme version corrigée :

```
ERROR ~ Validation of pipeline parameters failed!

 -- Check '.nextflow.log' file for details
The following invalid input values have been detected:

* --input (/home/fmt112/work/data_GM/samplesheet.csv): Validation of file failed:
        -> Entry 1: Error for field 'fastq_2' (/home/fmt112/work/data_GM/GM_fastq/SRR2045415_2.fastq): */home/fmt112/work/data_GM/GM_fastq/SRR2045415_2.fastq* does not match regular expression [^([\S\s]*\
/)?[^\s\/]+\.f(ast)?q\.gz$] (FastQ file for reads 2 cannot contain spaces and must have extension '.fq.gz' or '.fastq.gz')
        -> Entry 1: Error for field 'fastq_1' (/home/fmt112/work/data_GM/GM_fastq/SRR2045415_1.fastq): */home/fmt112/work/data_GM/GM_fastq/SRR2045415_1.fastq* does not match regular expression [^([\S\s]*\
/)?[^\s\/]+\.f(ast)?q\.gz$] (FastQ file for reads 1 must be provided, cannot contain spaces and must have extension '.fq.gz' or '.fastq.gz')
        -> Entry 2: Error for field 'fastq_2' (/home/fmt112/work/data_GM/GM_fastq/SRR2045416_2.fastq): */home/fmt112/work/data_GM/GM_fastq/SRR2045416_2.fastq* does not match regular expression [^([\S\s]*\
/)?[^\s\/]+\.f(ast)?q\.gz$] (FastQ file for reads 2 cannot contain spaces and must have extension '.fq.gz' or '.fastq.gz')
        -> Entry 2: Error for field 'fastq_1' (/home/fmt112/work/data_GM/GM_fastq/SRR2045416_1.fastq): */home/fmt112/work/data_GM/GM_fastq/SRR2045416_1.fastq* does not match regular expression [^([\S\s]*\
/)?[^\s\/]+\.f(ast)?q\.gz$] (FastQ file for reads 1 must be provided, cannot contain spaces and must have extension '.fq.gz' or '.fastq.gz')
```

Message (extrait) :
Validation of pipeline parameters failed … does not match regular expression … must have extension '.fq.gz' or '.fastq.gz'
Le pipeline **nf-core/rnavar** vérifie le samplesheet.csv avant de démarrer (validation *nf-schema*).
Il **exige des FASTQ compressés** avec les extensions **.fastq.gz** ou **.fq.gz**, sans espaces dans les chemins.
Nous avions fourni des fichiers **non compressés** (.fastq), d'où l'échec de la validation.

- **Troisième version du script corrigée :**

  Correction appliquée :

1- Compression des 4 fichiers :

```
fmt112@genobioinfo1 ~/work/data_GM $ cd GM_fastq/
fmt112@genobioinfo1 ~/work/data_GM/GM_fastq $ gzip -v SRR2045415_1.fastq SRR2045415_2.fastq SRR2045416_1.fastq SRR2045416_2.fastq
SRR2045415_1.fastq:

 73.9% -- replaced with SRR2045415_1.fastq.gz
SRR2045415_2.fastq:

 74.1% -- replaced with SRR2045415_2.fastq.gz
SRR2045416_1.fastq:      72.6% -- replaced with SRR2045416_1.fastq.gz
SRR2045416_2.fastq:      72.3% -- replaced with SRR2045416_2.fastq.gz
```

```
fmt112@genobioinfo1 ~/work/data_GM/GM_fastq $ ls
SRR2045415_1.fastq.gz  SRR2045416_1.fastq.gz
SRR2045415_2.fastq.gz  SRR2045416_2.fastq.gz
```

2- **Mise à jour** du `samplesheet.csv` pour pointer vers les **.fastq.gz**.

```
fmt112@genobioinfo1 ~/work/data_GM $ sed -i 's/\.fastq/.fastq.gz/g' samplesheet.csv
fmt112@genobioinfo1 ~/work/data_GM $ column -s, -t samplesheet.csv | sed -n '1,5p'
sample      fastq_1                                          fastq_2                                          strandedness
SRR2045415  /home/fmt112/work/data_GM/GM_fastq/SRR2045415_1.fastq.gz  /home/fmt112/work/data_GM/GM_fastq/SRR2045415_2.fastq.gz  auto
SRR2045416  /home/fmt112/work/data_GM/GM_fastq/SRR2045416_1.fastq.gz  /home/fmt112/work/data_GM/GM_fastq/SRR2045416_2.fastq.gz  auto
```

3- Nettoyage avant relance :

Pour repartir proprement après nos essais et éviter toute confusion avec d'anciens résultats, **nous avons effectué un nettoyage :**

```
fmt112@genobioinfo1 ~/work/data_GM $ rm run_rnavar.sbatch
fmt112@genobioinfo1 ~/work/data_GM $ rm -rf results_rnavar work_rnavar
fmt112@genobioinfo1 ~/work/data_GM $ rm slurm-*.out
fmt112@genobioinfo1 ~/work/data_GM $ ls
GM_Annotation  GM_fastq  GM_genome  pipeline_trace_hawa.txt  run_rnavar.sh  samplesheet.csv  sm_config.cfg
```

4- Script corrigé et relance du pipeline

```
fmt112@genobioinfo1 ~/work/data_GM $ nano run_rnavar.sh
fmt112@genobioinfo1 ~/work/data_GM $ more run_rnavar.sh
#!/bin/bash
#SBATCH -J rnavar
#SBATCH --cpus-per-task=8
#SBATCH --mem=32G
#SBATCH --time=24:00:00
#SBATCH -o slurm-%j.out
#SBATCH -p unlimitq

set -euo pipefail

module purge
module load devel/java/17.0.6
module load bioinfo/Nextflow/25.04.0
module load bioinfo/NextflowWorkflows/nfcore-Nextflow-v25.04.0

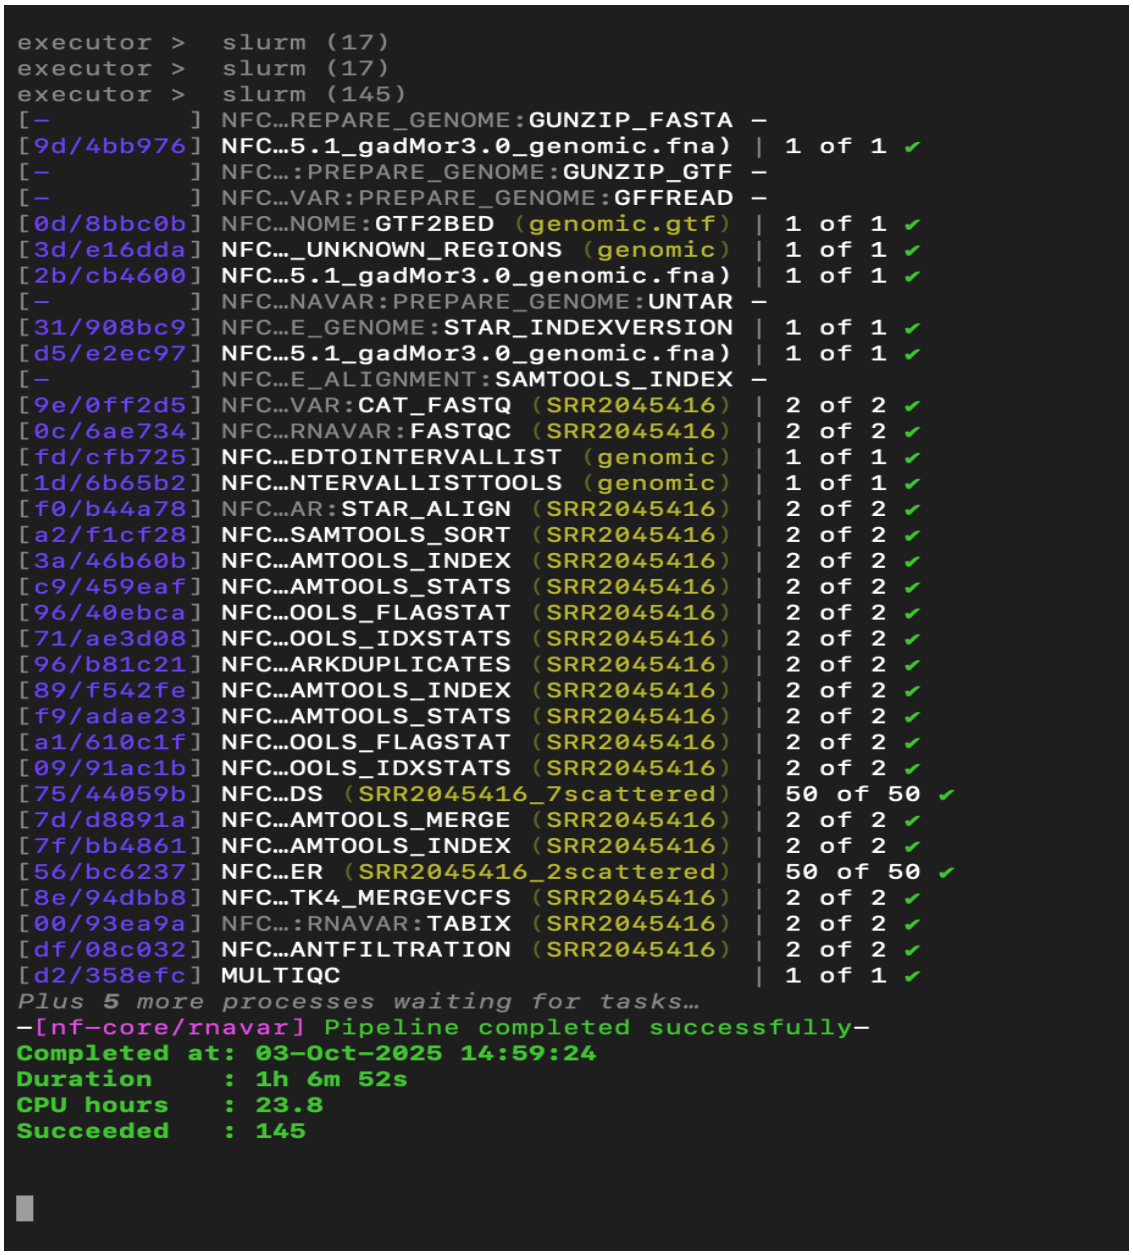
cd ~/work/data_GM
PWD="$(pwd)"

nextflow run nf-core/rnavar \
  -r 1.2.1 \
  -profile genotoul \
  -c sm_config.cfg \
  --input    "$PWD/samplesheet.csv" \
  --fasta    "$PWD/GM_genome/GCF_902167405.1_gadMor3.0_genomic.fna" \
  --gtf      "$PWD/GM_Annotation/genomic.gtf" \
  --outdir   "$PWD/results_rnavar" \
  --skip_baserecalibration \
  -work-dir "$PWD/work_rnavar" \
  -resume

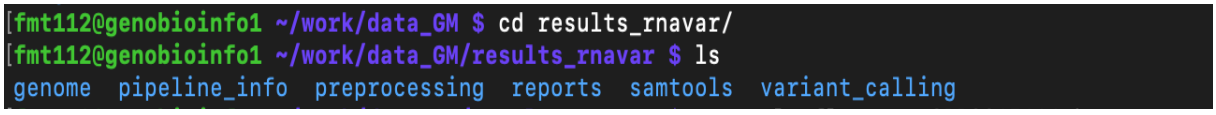
fmt112@genobioinfo1 ~/work/data_GM $ rm slurm-*.out
fmt112@genobioinfo1 ~/work/data_GM $ sbatch run_rnavar.sh
Submitted batch job 25060697
```

Après avoir corrigé et nettoyé (suppression du script .sbatch, des anciens résultats, et des logs SLURM), c'est le dernier script .sh qui a enfin fonctionné correctement. (voir capture d'écran ci-dessous).

Avec ces ajustements, l'exécution s'est déroulée sans erreur et le pipeline **nf-core/rnavar** a pu aller jusqu'au bout, en produisant les résultats attendus dans `results_rnavar/`.



3- Résultats :



A- **Contenu du dossier `results_rnavar/`**

1. **genome/**
   - Contient les fichiers liés à la préparation du génome de référence (index STAR, dictionnaires, fichiers .dict, .fai, etc.).
   - Ces fichiers sont nécessaires pour l'alignement et les étapes de variant calling.
2. **pipeline_info/**
   - Informations sur le run Nextflow : logs, version du pipeline, configuration utilisée, durée, ressources consommées.
   - Sert de traçabilité pour savoir exactement dans quelles conditions l'analyse a été réalisée.
3. **preprocessing/**
   - Résultats du prétraitement des FASTQ (FastQC, trimming si activé, statistiques sur la qualité).
   - On y trouve généralement les rapports de qualité initiaux des séquences.
4. **reports/**
   - Contient les rapports finaux, notamment le **rapport MultiQC** qui synthétise toutes les étapes (qualité des reads, alignements, duplication, stats de variants).
   - C'est le document clé pour une vue globale.
5. **samtools/**
   - Résultats liés aux fichiers BAM générés après l'alignement (statistiques d'alignement, taux de couverture, duplication, indexation).
   - Permet de vérifier si les lectures se sont bien alignées sur le génome de référence.
6. **variant_calling/**
   - Résultats finaux de l'appel de variants : fichiers **VCF** (variants détectés), filtrés ou bruts.
   - C'est ici que se trouve la sortie biologique la plus importante : les variants identifiés dans nos échantillons (SNPs, indels).

B- **Analyse des résultats :**

1- **Qualité de l'alignement des lectures (samtools)**

Dans le dossier samtools/, le pipeline a généré plusieurs fichiers de statistiques à partir des alignements BAM.

samtools flagstat :

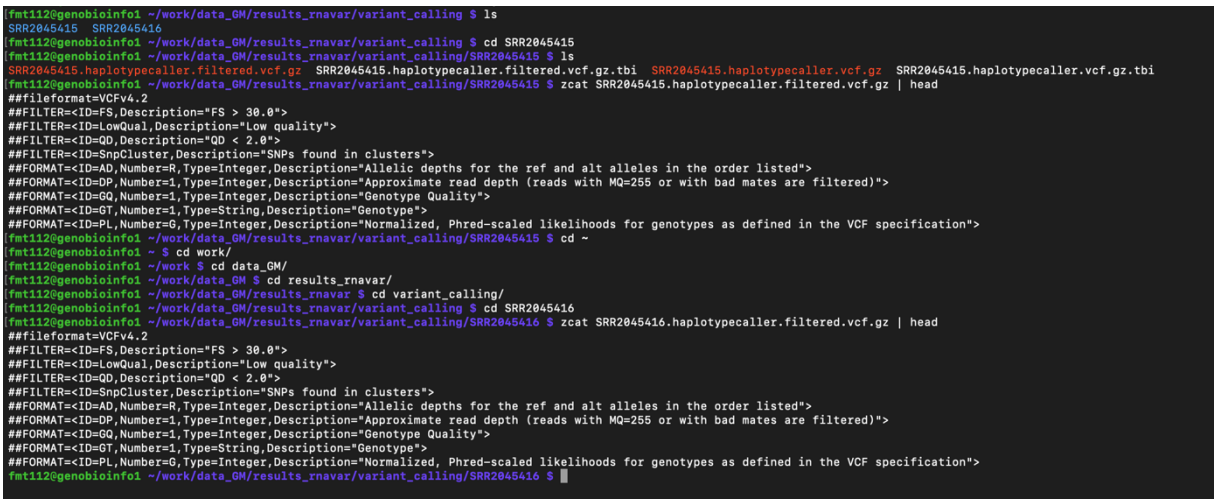
Donne un résumé global des alignements :

- nombre total de reads,
- pourcentage de reads alignés,
- proportion de reads appariés correctement.

```
[fmt112@genobioinfo1 ~/work/data_GM/results_rnavar/samtools $ ls
SRR2045415.bam  SRR2045415.bam.bai  SRR2045416.bam  SRR2045416.bam.bai
[fmt112@genobioinfo1 ~/work/data_GM/results_rnavar/samtools $ samtools flagstat SRR2045415.bam
44744578 + 0 in total (QC-passed reads + QC-failed reads)
40216346 + 0 primary
4528232 + 0 secondary
0 + 0 supplementary
0 + 0 duplicates
0 + 0 primary duplicates
44744578 + 0 mapped (100.00% : N/A)
40216346 + 0 primary mapped (100.00% : N/A)
40216346 + 0 paired in sequencing
20108173 + 0 read1
20108173 + 0 read2
40216346 + 0 properly paired (100.00% : N/A)
40216346 + 0 with itself and mate mapped
0 + 0 singletons (0.00% : N/A)
0 + 0 with mate mapped to a different chr
0 + 0 with mate mapped to a different chr (mapQ>=5)
fmt112@genobioinfo1 ~/work/data_GM/results_rnavar/samtools $ samtools flagstat SRR2045416.bam
59832912 + 0 in total (QC-passed reads + QC-failed reads)
56448558 + 0 primary
3384354 + 0 secondary
0 + 0 supplementary
0 + 0 duplicates
0 + 0 primary duplicates
59832912 + 0 mapped (100.00% : N/A)
56448558 + 0 primary mapped (100.00% : N/A)
56448558 + 0 paired in sequencing
[28224279 + 0 read1
28224279 + 0 read2
56448558 + 0 properly paired (100.00% : N/A)
56448558 + 0 with itself and mate mapped
0 + 0 singletons (0.00% : N/A)
0 + 0 with mate mapped to a different chr
0 + 0 with mate mapped to a different chr (mapQ>=5)
fmt112@genobioinfo1 ~/work/data_GM/results_rnavar/samtools $
```

Les deux échantillons (SRR2045415 et SRR2045416) présentent une **qualité d'alignement excellente**, avec **100 % de reads mappés** et **aucun problème de duplication**. Cela confirme la pertinence du génome de référence utilisé et la bonne qualité des données.

2- Les variants détectés :



Chaque échantillon a donné lieu à un **VCF brut** (non filtré) et un **VCF filtré** (résultats fiables).

Les **VCF filtrés** sont ceux que l'on interprète biologiquement.

Les résultats constituent la **liste finale des variants détectés** dans les transcriptomes des échantillons de *Gadus morhua*.

Les variants détectés dans les deux échantillons (SRR2045415 et SRR2045416) correspondent principalement à des **SNPs (Single Nucleotide Polymorphisms)** et à des **indels (insertions/délétions)** identifiés à partir des lectures ARN alignées sur le génome de *Gadus morhua*.

3- Rapport global (MultiQC)

Le pipeline a généré, dans le dossier **reports/**, un fichier **multiqc_report.html**.
Ce rapport regroupe automatiquement l'ensemble des résultats clés sous forme de graphiques et de tableaux :

- **Qualité initiale des lectures (FastQC)** → score de qualité, contenu GC, sur/sous-représentation de séquences.
- **Alignements (Samtools/STAR)** → taux de reads alignés, profondeur de couverture, duplications.
- **Variant calling (GATK HaplotypeCaller)** → nombre total de variants détectés, répartition SNPs/indels, distribution de la qualité.

```
fmt112@genobioinfo1 ~/work/data_GM/results_rnavar/reports $ ls
multiqc_data  multiqc_plots  multiqc_report.html  stats
fmt112@genobioinfo1 ~/work/data_GM/results_rnavar/reports $ less multiqc_report.html
fmt112@genobioinfo1 ~/work/data_GM/results_rnavar/reports $ head -n 20 multiqc_report.html
<!DOCTYPE html>
<html lang="en">
<head>
<!--
  __  __       _ _   _  ___   ____
 |  \/  |_   _| | |_(_)/ _ \ / ___|
 | |\/| | | | | | __| | | | | |
 | |  | | |_| | | |_| | |_| | |___
 |_|  |_|\__,_|_|\__|_|\__\_\\____|

Abandon hope all ye who enter here..
http://multiqc.info
-->
[
[


<meta charset="utf-8">
<meta http-equiv="X-UA-Compatible" content="IE=edge">
<meta name="viewport" content="width=device-width, initial-scale=1">
```

4- Conclusion :

Au final, ce projet nous a permis de prendre en main **Nextflow** et le pipeline **nf-core/rnavar** pour analyser des données RNA-Seq de *Gadus morhua*. Après avoir récupéré les données (FASTQ, génome et annotation) et surmonté quelques erreurs

techniques liées aux formats de fichiers et à la configuration du script, le pipeline a pu être exécuté correctement sur le cluster Genotoul.

Les résultats montrent que l'alignement des lectures s'est très bien déroulé, avec quasiment **100 % des lectures mappées** pour les deux échantillons. Le pipeline a ensuite généré des fichiers **VCF** contenant les variants détectés, ainsi qu'un rapport **MultiQC** résumant la qualité des données et de l'ensemble du traitement.

Ce travail nous a permis de mieux comprendre l'intérêt d'un pipeline comme **rnavar** : automatiser une série d'étapes complexes, garantir la reproductibilité de l'analyse et rendre possible le traitement de grands volumes de données. C'est une approche pratique et efficace pour étudier la variation génétique à partir de données RNA-Seq.